Generalitat de Catalunya Departament d'Educació i Formació Professional **Institut Sa Palomera**	**Projecte** ***Clustering***	institut sa palomera
Curs 2025-2026		**Sistemes d'aprenentatge automàtic**

CONTEXT

En aquest projecte treballarem amb **dades reals de competicions FEB** (https://baloncestoenvivo.feb.es/home.aspx) emmagatzemades en una base de dades **MongoDB**.

L'objectiu és **descobrir patrons ocults** mitjançant tècniques d'aprenentatge automàtic **no supervisat**, tant a nivell de **jugadors o d'equips**, utilitzant **K-Means** i/o **DBSCAN**.

🎯 OBJECTIUS GENERALS

L'alumnat haurà de ser capaç de:

- Importar o connectar-se a una base de dades NoSQL (MongoDB)
- Dissenyar un **procés ETL complet** orientat a Machine Learing
- Construir un **model de *clustering* no supervisat** en Python.
- **Interpretar** i donar sentit esportiu als **clústers obtinguts**.
- Visualitzar dades complexes i **extreure insights**.
- Comunicar conclusions

📦 ORIGEN DE DADES

- Conjunt de dades
  - Fitxer `backup_feb_db_2026-01-07.archive` **(GDrive alumnes_share)**
- Restaurar el conjunt de dades

```
mongorestore --uri="" --gzip --archive="2026-01-08_feb_db_bkp.archive.gz"
```

- Base de dades, col·lecció i vistes:
  - Base de dades: **`feb_db`**
  - Col·lecció `partits`(~109.200): Estadístiques dels partits
  - Vista `FEB3_players_shots` (~1.170.000): Tots els llançaments que ha realitzat cada jugador
  - Vista `FEB3_players_statistics` (~204.000): Estadístiques individuals d'un jugador en un partit concret.
  - Vista `FEB3_teams_statistics`(~18.000): Estadístiques individuals d'un equip en un partit concret.
- A l'**Annex del projecte** es descriurà detalladament amb el significat de **cada camp**

PART 1 – ETL/EDA i model de dades (30%)

🎯 **Ojectiu:** Transformar dades crues de MongoDB en un **dataset net, coherent i preparat per ML**.

📌 **Tasques a realitzar**

- **Connexió a MongoDB**
  - Connexió mitjançant pymongo
  - Consulta selectiva de dades (filtrat per temporada, competició, etc.)
- **Disseny del model de dades analític**
  - Quin serà el nivell d'anàlisi per jugador (mitjanes per partit)
  - Escollir quines variables són rellevants per fer clustering
- **Neteja i transformació**
  - Tractament de:
    - valors nuls (null)
    - minuts = 0
    - jugadors amb poca mostra
    - Normalització / estandardització (StandardScaler, MinMaxScaler)
  - Creació de noves estadístiques:
    - Possessions d'un equip en un partit
    - OER i DER
    - Ús de tirs de 2
    - Ús de tirs de 3
    - eficàcia per zona de tir
    - percentatge de tirs interiors vs exteriors
- **Dataset final**
  - Creació d'un DataFrame final documentat
  - Justificació de les variables escollides

📦 **Entrega:**

- **Notebook o script Python amb tot l'ETL**

PART 2 – Model de Machine Learning (40%)

🎯 **Ojectiu:** Aplicar clustering no supervisat per descobrir tipologies de jugadors i/o equips.

📌 Tasques a realitzar

- **Elecció del model**
  - L'alumnat haurà d'utilitzar el model **K-Means**
  - Es valorarà la comparació amb el model **DBSCAN**
- **Entrenament del model**
  - Elecció de:
    - Nombre de clústers (k)
      - Mètriques de qualitat: Inertia, silhouette score
- **Interpretació dels clústers**
  - Cada clúster ha de tenir:
    - Una **descripció esportiva clara**
    - Un **nom representatiu**
  - Exemples:
    - Tiradors purs,
    - Pivots interiors
    - Pivots oberts amb tir exterior
    - Guards/bases generador de joc
    - Equips defensius
    - Equips de ritme alt ofensiu

📦 Entrega:

- **Notebook o script Python amb tot l'ETL**
- **Codi Python del model**
- **Taula resum amb mitjanes per clúster**

PART 3 – Visulització i conclusions (30%)

🎯 **Ojectiu:** Comunicar resultats com un **data analyst professional**.

📌 **Tasques a realitzar**

- **Visualització de dades**
  - Utilització de plots per explicar les dades amb les que partíem i els resultats obtinguts.
  - t-SNE (opcional, però serà valorat)
  - Gràfics comparatius entre clústers.
  - *Heatmaps* de zones de tirs (players_shots)
- **Entrenament del model**
  - Elecció de:
    - Nombre de clústers (k)
      - Mètriques de qualitat: Inertia, silhouette score
- **Interpretació dels clústers**
  - Cada clúster ha de tenir:
    - Una **descripció esportiva clara**
    - Un **nom representatiu**
  - Exemples:
    - Tiradors purs,
    - Pivots interiors
    - Pivots oberts amb tir exterior
    - Guards/bases generador de joc
    - Equips defensius
    - Equips de ritme alt ofensiu

📦 **Entrega:**

- **Notebook o script Python amb tot l'ETL**
- **Codi Python del model**
- **Taula resum amb mitjanes per clúster**

ENTREGA GITHUB

L'entrega de l'activitat s'ha de realitzar en un repositori de **GitHub** a on es vegi clarament les els diferents apartats demanats juntament amb les entregues de notebooks, scripts i/o documentació complementària

PART OPCIONAL – Enriquiment amb dades externes (+10%)

Ojectiu: Millorar el model afegint dades personals dels jugadors.

Tasques a realitzar

- **Realitzar un web scraping de la web oficial FEB.** Per exemple **dades dels jugadors**: posició, altura, pes, data de naixement, nacionalitat, si és de formació (booleà)
  - https://baloncestoenvivo.feb.es/equipo/<id_equip>
- **Integració d'aquestes dades e la BD del model.**
- **Afegir algunes d'aquestes característiques dels jugadors en el model**

📎 ANNEX - Explicació detallada de les estadístiques de bàsquet

Vista `FEB3_players_shots`: Dades de tots els llançaments que s'han realitzat

`"player_feb_id": "2451417":` Identificador del jugador per la FEB

`"player_number": "4":` Dorsal del jugador.

`"team": "L":` Si és local (L)o Visitant(V)

`"team_feb_id": "923496":` Identificador de l'equip del jugador.

`"team_name": "JAEN PARAISO INTERIOR FS":` Nom de l'equip

`"quarter": "3":` quart a on s'ha realitzat el llançament

`"time": "02:07",:` minut dins del quart on s'ha realitzat el llançament

`"made": true:` El tir s'ha materialitzat(ha entrat) o no.

`"x": 71.99998872544994:` Coordenada X de la posició del llançament

`"y": 84.28541424353205:` Coordenada Y de la posició del llançament

`"player_name": "A. NOSA CASTILLO":` Nom del jugdor

`"court_region": "Ce3R":` Espai d'on s'ha realitzat el llançament (C3R, E3R, Ce3R, Ce3L, E3L, C3L, MBR, MER, MEL, MBL, PR, PC, PL)

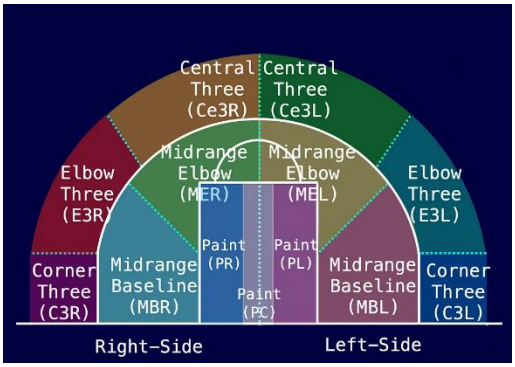

`"competion_feb_id": "111":` Identificador de la competició

`"competition_name": "LIGA EBA":` Nom de la competició

`"season_id": "2023-2024":` Identificador de la temporada

`"phase_feb_id": "85388":` Identificador de la fase dins la competició.

`"phase_feb_name": "FF 2°A1-2°A2 2°A1-2°A2":` Nom de la fase dins la competició.

`"subphase_feb_id": null:` Identificador de la subfase

`"suphase_feb_name": "suphase_feb_name":`Nom de la subfase

`"round_feb_id": "640706":` Identificador de la ronda/jornada

`"round_feb_name1": "Jornada 1(12/05/2024)",:` Nom de la ronda/jornada

`"round_feb_name2": "2°A1-2°A2":` Nom alternatiu de la ronda

`"match_feb_id": "2400233":` Identificador del partit

`"data": "12-05-2024":` Data partit

`"hora": "17:00":` Hora partit

`"type": "3p":` Tipus tir ("3p" / "2p")

Vista `FEB3_players_statistics`: Estadístics individuals d'un jugador en un partit concret.

`"competition_feb_id": "111":` Identificador de la competició

`"competition_name": "LIGA EBA":` Nom de la competició

`"season_id": "2023-2024":` Identificador de la temporada

`"phase_feb_id": "85388":` Identificador de la fase

`"phase_feb_name": "FF 2°A1-2°A2 2°A1-2°A2":` Nom de la fase

`"subphase_feb_id": null:` Identificador de la subfase

`"subphase_feb_name": null:` Nom de la subase

`"round_feb_id": "640706":` Identificador de la ronda/jornada

`"round_feb_name1": "Jornada 1(12/05/2024)":` Nom de la jornada/ronda

`"round_feb_name2": "2°A1-2°A2":` Nom alternatiu de la jornada/ronda

`"match_feb_id": "2400233":` Identificador del partit

`"data": "12-05-2024":` Data del partit

`"hora": "17:00":` Hora del partit

`"local": 1:` Jugava com a local (1)o visitant (0)

`"team_feb_id": "923496":` Identificador de l'equip

`"team_name": "JAEN PARAISO INTERIOR FS":` Nom de l'equip

`"team_feb_code": "23560100":` codi feb de l'equip

`"team_club_feb_code": "235601":` codi del club de l'equip.

`"player_feb_id": "1633525":` Identificador del jugador

`"player_name": "P. AGUDO LASO":` Nom del jugador

`"player_number": "0":` Dorsal del jugador

`"starter": 0:` Si ha començat com a titular o no.

`"pts": 0:` Punts del jugador

`"minutes": 0:` segons jugats

`"ftm": 0:` Tirs lliures fets

`"fta": 0:` Tirs lliures intentats

`"2pm": 0:` 2p fets

`"2pa": 0:` 2p intentats

`"ppt2": null:` Punts per intent de 2 punts (2*2pm/2pa)

`"3pm": 0:` 3p fets

`"3pa": 0:` 3p intentats

`"ppt3": null:` Punts per intent de 3 punts (3*3pm/3pa)

`"fgm": 0:` tirs de camp fets

`"fga": 0:` tirs de camp intentats

`"fg": null:` ratio de tirs de camp (fgm/fga)

`"pps": null:` punts per llançament((2*2pm)+(3*"3pm))/fga

`"tsa": 0,` true shooting intentats (fga+ 0.44*fta)

`"ts": null:` true shooting (pts/(2*tsa)

`"efg": null,` eficiència de tir (fgm + 0.5·2pa + 3·3pa)

`"tov": 0:` Pilotes perdudes

`"stl": 0:` Pilotes robades

`"ast": 0:` Assistències

`"ast2p": null:` Assistències de 2 punts

`"ast3p": null:` Assistències de 3 punts

`"astfd": null:` Ignorar

`"orb": 0:` Rebots ofensius

`"drb": 0:` Rebots defensius

`"trb": 0:` Total de rebots

`"blk": 0:` taps realitats

`"blka": 0:` taps contra

`"pf": 0:` Faltes comeses

`"pfd": 0:` Faltes rebudes

`"dunk": 0:` Esmaixades

`"ftr": null:` Tirs lliures intentats respecte el tirs de camp intentats

`"eff_spanish": 0:` Valoració del jugador

`"balance": 0:` Balanç +/-

`"rc_pc_m": 0:` tirs a PC realitats

`"rc_pc_a": 0:` tirs a PC intentats

`"rc_pl_m": 0:` tirs a PL realitats

`"rc_pl_a": 0:` tirs a PL intentats

`"rc_pr_m": 0:` tirs a PR realitzats

`"rc_pr_a": 0:` tirs a PR intentats

`"rc_mbl_m": 0:` tirs a MBL realitzats

`"rc_mbl_a": 0:` tirs a MBL intentats

`"rc_mbr_m": 0:` tirs a MBR realitzats

`"rc_mbr_a": 0:` tirs a MBR intentats

`"rc_mel_m": 0:` tirs a MEL realitzats

`"rc_mel_a": 0:` tirs a MEL intentats

`"rc_mer_m": 0:` tirs a MER realitzats

`"rc_mer_a": 0:` tirs a MER intentats

`"rc_c3l_m": 0:` tirs a C3L realitzats

`"rc_c3l_a": 0:` tirs a C3L intentats

`"rc_c3r_m": 0:` tirs a C3R realitzats

`"rc_c3r_a": 0:` tirs a C3R intentats

`"rc_ce3l_m": 0:` tirs a Ce3L realitzats

`"rc_ce3l_a": 0:` tirs a Ce3L intentats

`"rc_ce3r_m": 0:` tirs a Ce3R realitzats

`"rc_ce3r_a": 0:` tirs a Ce3R intentats

`"rc_e3l_m": 0:` tirs a E3L realitzats

`"rc_e3l_a": 0:` tirs a E3L intentats

`"rc_e3r_m": 0:` tirs a E3R realitzats

`"rc_e3r_a": 0:` tirs a E3R intentats

Vista `FEB3_teams_statistics`: Estadístics d'un equip en un partit concret.

`"win": 0:` Indica si ha guanyat(1) o no(0)

`"pts": 68:` Punts totals de l'equip

`"minutes": 12000:` segons jugats de l'equip

`"ftm": 11:` Tirs lliures realitzats

`"fta": 21:` Tirs lliures intentats

`"2pm": 15:` Tirs 2p realitzats

`"2pa": 35:` Tirs 2p intentats

`"3pm": 9:` Tirs 3p realitzats

`"3pa": 27:` Tirs 3p intentats

`"fgm": 24:` Tirs de camp intentats

`"fga": 62:` Tirs de camp realitzats

`"fg": 3.9832334332334334:` ratio de tirs de camp (fgm/fga)

`"pps": 34.79090909090909:` punts per llançament((2*2pm)+(3*"3pm))/fga

`"tsa": 71.24:` true shooting intentats (fga+ 0.44*fta)

`"ts": 5.50843269644502:` true shooting (pts/(2*tsa)

`"efg": 0.4347016619743893:` eficiència de tir (fgm + 0.5·2pa + 3·3pa)

`"tov": 21:` Pilotes perdudes

`"stl": 6:` Pilotes robades

`"ast": 13:` Assistències

`"orb": 12:` Rebots ofensius

`"drb": 28:` Rebots defensius

`"trb": 40:` Total rebots

`"blk": 2:` Taps realitats

`"blka": 1:` Taps en contra

`"pf": 19:` Faltes personals

`"pfd": 20:` Faltes personals rebudes

`"dunk": 1:` Esmaixades

`"ftr": 0.3905155450609996:` Tirs lliures intentats respecte el tirs de camp intentats

`"eff_spanish": 61:` Valoració de l'equip

`"season_id": "2024-2025":` Identificador de la temporada

`"competition_feb_id": "111":` Identificador de la comeptició

`"competition_name": "Liga EBA":` Nom de la competició

`"phase_feb_id": "86381":` Identificador de la fase

`"phase_feb_name": "Liga Regular \"B-A\"":` Nom de la fase

`"subphase_feb_id": null:` Identificador de la subfase

`"round_feb_id": "643598":` Identificador de la ronda/jornada

`"round_feb_name1": "Jornada 2(20/10/2024)":` Nom de la ronda/jornada

`"round_feb_name2": null:` Nom alternatiu ronda/jornada

`"match_feb_id": "2413612":` Identificador del partit

`"data": "19-10-2024":` Data del partit

`"hora": "19:30":` Hora del partit

`"team_feb_id": "952028":` Identificador de l'equip

`"team_name": "PABLO LASO ACADEMY":` Nom de l'equip

`"team_feb_code": "28297381":` Codi FEB de l'equip

`"local": 1:` Si l'equip jugava com a local o visitant (1=local,0=visitant)